



Random Forest Algoritması ile Tiroid Hastalığı Sınıflandırması

Hazırlayan: ESMA BİLEN

Öğrenci Numarası: 23360859035

Haziran 2026

İçindekiler

1.Proje Özeti.....	3
2.Giriş.....	3
3.Veri Seti.....	4
4.Veri Ön İşlemesi.....	4
5.Kullanılan Yöntem: Random Forest.....	5
6.Deneysel Sonuçlar.....	5
6.1 Model Performanslarının Karşılaştırılması.....	5
6.2 Random Forest Confusion Matrix Analizi.....	6
6.3 Feature Importance.....	7
7.Literatür Karşılaştırması.....	7
8.Sonuç ve Öneriler.....	8
9.Kaynakça.....	9

YouTube bağlantısı:

<https://www.youtube.com/watch?v=RlZ-wynyOAc>

GitHub Linki:

<https://github.com/esmabilen37/thyroid-disease-classification>

1.Proje Özeti

Bu projede UCI Machine Learning Repository üzerinde yer alan Thyroid Disease veri seti kullanılarak tiroid hastalığı var/yok sınıflandırması yapılmıştır. Çalışmanın ana yöntemi olarak karar ağacı tabanlı bir öğrenme algoritması olan Random Forest seçilmiştir. Veri setindeki orijinal hedef değişken, “hastalık yok” ve “hastalık var” olmak üzere ikili sınıflandırma problemine dönüştürülmüştür.

Çalışmada öncelikle eksik değerler giderilmiş, kategorik değişkenler sayısal forma dönüştürülmüş ve veri seti eğitim-test olarak ayrılmıştır. Ana model olan Random Forest’ın yanı sıra karşılaştırma amacıyla Decision Tree ve hiperparametre optimizasyonu uygulanmış Tuned Random Forest modelleri de denenmiştir. Modeller accuracy, sensitivity, specificity, precision ve F1-score metrikleriyle değerlendirilmiştir.

Elde edilen sonuçlara göre Random Forest modeli %96.29 doğruluk oranı elde etmiştir. Tuned Random Forest modeli hasta sınıfı için daha yüksek sensitivity değeri sağlamış, Decision Tree modeli ise accuracy açısından az farkla daha yüksek sonuç vermiştir. Sonuçlar, Random Forest tabanlı yöntemlerin tiroid hastalığı sınıflandırmasında başarılı şekilde kullanılabileceğini göstermektedir.

2. Giriş

Tiroid bezi, insan metabolizmasının düzenlenmesinde önemli rol oynayan hormonları üretmektedir. Tiroid bezinde meydana gelen bozukluklar, bireylerin yaşam kalitesini olumsuz etkileyebilen çeşitli hastalıklara neden olabilmektedir. Hipotiroidi ve hipertiroidi gibi rahatsızlıkların erken teşhisi, uygun tedavi süreçlerinin planlanabilmesi açısından büyük önem taşımaktadır.

Günümüzde sağlık alanında üretilen veri miktarının artmasıyla birlikte makine öğrenmesi ve veri madenciliği yöntemleri, hastalık teşhisi ve tahmin çalışmalarında yaygın olarak kullanılmaya başlanmıştır. Bu yöntemler sayesinde laboratuvar sonuçları ve klinik veriler kullanılarak hastalıkların otomatik olarak sınıflandırılması mümkün hale gelmiştir.


Bu çalışmada UCI Machine Learning Repository’de yer alan Thyroid Disease veri seti kullanılarak tiroid hastalığı var/yok sınıflandırması gerçekleştirilmiştir. Çalışmanın ana yöntemi olarak Random Forest algoritması seçilmiş, sonuçların değerlendirilmesi amacıyla Decision Tree ve hiperparametre optimizasyonu uygulanmış Tuned Random Forest modelleri ile karşılaştırmalar yapılmıştır.

3. Veri Seti

Bu çalışmada UCI Machine Learning Repository üzerinde yayınlanan Thyroid Disease veri seti kullanılmıştır. Veri seti tiroid hastalıklarının teşhisinde kullanılan çeşitli klinik ve laboratuvar değişkenlerini içermektedir.

Veri seti toplam 9172 gözlem ve 30 değişkenden oluşmaktadır. Değişkenler arasında yaş, cinsiyet, çeşitli ilaç kullanımları, laboratuvar test sonuçları ve yönlendirme bilgileri bulunmaktadır.

Veri setinin orijinal hedef değişkeni çok sınıflı bir yapıya sahiptir. Ancak sınıfların önemli ölçüde dengesiz olması ve bazı sınıflarda çok az örnek bulunması nedeniyle problem ikili sınıflandırma problemine dönüştürülmüştür. Bu dönüşümde "-" etiketi hastalık yok sınıfını, diğer tüm etiketler ise hastalık var sınıfını temsil edecek şekilde yeniden kodlanmıştır. Veri setindeki sınıf dağılımı Şekil 1'de gösterilmiştir.



Şekil 1. Tiroid hastalığı veri setindeki sınıf dağılımı

4. Veri Ön İşlemesi

Veri ön işleme aşamasında ilk olarak veri setindeki hedef değişken temizlenmiş ve ikili sınıf yapısına dönüştürülmüştür. Daha sonra eksik değerler incelenmiştir. Sayısal değişkenlerde eksik değerler medyan değeri ile kategorik değişkenlerde ise mod ile doldurulmuştur.

Makine öğrenmesi algoritmalarının kullanılabilmesi amacıyla kategorik değişkenler Label Encoding yöntemi ile sayısal değerlere dönüştürülmüştür.

Veri seti %80 eğitim ve %20 test olacak şekilde eğitim ve test kümelerine ayrılmıştır. Veri setinde sınıf dengesizliği bulunduğu için Random Forest modelinde `class_weight="balanced"` parametresi kullanılmıştır. Veri setinin başlangıçtaki dengesizliği Tablo 1'de gösterilmiştir.

	Sınıf	Sayı	Oran (%)
0	Hastalık Yok	6771	73.82
1	Hastalık Var	2401	26.18

Tablo 1. Veri setindeki sınıf dağılımı

5. Kullanılan Yöntem: Random Forest

Bu çalışmada ana sınıflandırma yöntemi olarak Random Forest algoritması kullanılmıştır. Random Forest, birden fazla karar ağacının bir araya getirilmesiyle oluşturulan ensemble öğrenme yöntemlerinden biridir.

Random Forest algoritmasının tercih edilme nedenleri şunlardır:

- Karar ağaçlarına göre daha düşük overfitting riski taşıması
- Hem kategorik hem sayısal değişkenlerle çalışabilmesi
- Gürültülü verilere karşı dayanıklı olması
- Özellik önem düzeylerini hesaplayabilmesi
- Sağlık verileri gibi karmaşık veri yapılarında başarılı sonuçlar verebilmesi

Bu çalışmada Random Forest modeli 100 ağaç kullanılarak eğitilmiştir. Ayrıca hiperparametre optimizasyonunun etkisini incelemek amacıyla GridSearchCV yöntemi kullanılarak Tuned Random Forest modeli oluşturulmuştur.

6. Deneysel Sonuçlar

Bu bölümde çalışmanın ana yöntemi olan Random Forest modelinin performansı değerlendirilmiştir. Ana modelin sonuçlarını daha anlamlı yorumlayabilmek amacıyla Decision Tree modeli karşılaştırma modeli olarak kullanılmıştır. Ayrıca hiperparametre optimizasyonunun Random Forest üzerindeki etkisini incelemek için GridSearchCV ile Tuned Random Forest modeli oluşturulmuştur. Modeller accuracy, sensitivity, specificity, precision ve F1-score metrikleri kullanılarak karşılaştırılmıştır.

6.1 Model Performanslarının Karşılaştırılması

Modellerin performansları accuracy, sensitivity, specificity, precision ve F1-score metrikleri kullanılarak değerlendirilmiştir. Elde edilen sonuçlar Tablo 2'de gösterilmektedir.

	Model	Accuracy	Sensitivity / Recall	Specificity	Precision	F1-score
0	Random Forest	0.962943	0.933333	0.973432	0.925620	0.929461
1	Decision Tree	0.966757	0.937500	0.977122	0.935551	0.936524
2	Tuned Random Forest	0.964033	0.939583	0.972694	0.924180	0.931818


Tablo 2. Modellerin performans karşılaştırması

Tablo 2 incelendiğinde tüm modellerin yüksek performans gösterdiği görülmektedir. Accuracy açısından en yüksek sonuç %96.66 ile Decision Tree modelinde elde edilmiştir. Bununla birlikte sağlık uygulamalarında hasta bireyleri doğru tespit etmek önemli olduğundan sensitivity metriği kritik öneme sahiptir. Sensitivity değeri açısından en yüksek sonuç %93.96

ile Tuned Random Forest modelinde elde edilmiştir. Ana model olarak kullanılan Random Forest algoritması ise %96.29 doğruluk ve %93.33 sensitivity değeri ile başarılı sonuçlar vermiştir.

6.2 Random Forest Confusion Matrix (Karışıklık Matrisi) Analizi

Random Forest modelinin sınıflandırma performansını daha ayrıntılı incelemek amacıyla confusion matrix oluşturulmuştur. Confusion matrix sonuçları Şekil 2'de gösterilmektedir.




Şekil 2. Random Forest confusion matrixi

Şekil 2 incelendiğinde Random Forest modelinin hastalık olmayan 1355 örneğin 1319'unu doğru şekilde sınıflandırdığı görülmektedir. Hastalık olmayan 36 örnek yanlışlıkla hastalık var olarak tahmin edilmiştir. Hastalık bulunan 480 örneğin ise 448'i doğru şekilde tespit edilmiş, 32 örnek ise hastalık yok olarak sınıflandırılmıştır.

Elde edilen sonuçlar modelin her iki sınıf üzerinde de yüksek performans gösterdiğini ortaya koymaktadır. Özellikle hasta sınıfı için elde edilen %93.33 sensitivity değeri, Random Forest algoritmasının tiroid hastalığı var/yok sınıflandırmasında etkili sonuçlar üretebildiğini göstermektedir.

6.3 Feature Importance (Özellik Önem Analizi)

Random Forest algoritmasının önemli avantajlarından biri, sınıflandırma sürecinde hangi değişkenlerin daha etkili olduğunu belirleyebilmesidir. Bu amaçla model tarafından hesaplanan özellik önem (feature importance) değerleri incelenmiştir. Elde edilen sonuçlar Şekil 3'te gösterilmektedir.



Şekil 3. Random Forest algoritmasına ait özellik önem grafiği

Şekil 3 incelendiğinde model üzerinde en yüksek etkiye sahip değişkenlerin TSH, T3, FTI, TT4 ve T4U olduğu görülmektedir. Bu değişkenler tiroid hastalıklarının teşhisinde kullanılan temel laboratuvar testleri arasında yer almaktadır.

Ayrıca yaş (age) ve referral_source gibi değişkenlerin de sınıflandırma sürecine belirli düzeyde katkı sağladığı görülmektedir. Bununla birlikte model kararlarının büyük ölçüde laboratuvar test sonuçlarına dayandığı anlaşılmaktadır.

7. Literatür Karşılaştırması

Bu çalışmada elde edilen sonuçların değerlendirilmesi amacıyla literatürde aynı veri setini kullanan akademik çalışmalar incelenmiştir. Karşılaştırma için Akhtar ve arkadaşları (2022) tarafından gerçekleştirilen “*Ensemble-based Effective Diagnosis of Thyroid Disorder with Various Feature Selection Techniques*” adlı çalışma seçilmiştir. İlgili çalışmada bu projede kullanılan Thyroid0387 veri seti kullanılmış ve çeşitli özellik seçme yöntemleri ile topluluk öğrenme (ensemble learning) yaklaşımları bir arada değerlendirilmiştir. Çalışmada Recursive Feature Elimination (RFE), Select From Model (SFM) ve Select K-Best (SKB) yöntemleri kullanılarak özellik seçimi yapılmış, ardından Bagging, Boosting ve Voting tabanlı topluluk öğrenme algoritmaları uygulanmıştır.

Akhtar vd. çalışmasında kullanılan veri seti üç sınıflı bir problem olarak ele alınmıştır. Hedef değişken; Normal, Hyperthyroidism ve Hypothyroidism olmak üzere üç farklı sınıfa ayrılmıştır. Buna karşılık bu projede veri seti “Hastalık Var” ve “Hastalık Yok” olmak üzere ikili sınıflandırma problemine dönüştürülmüştür. Bu nedenle iki çalışma doğrudan birebir karşılaştırılabilir olmamakla birlikte, aynı veri seti üzerinde farklı makine öğrenmesi yaklaşımlarının performanslarını değerlendirmek açısından karşılaştırma yapılmıştır.

Akhtar vd. tarafından önerilen yöntemde %99,27 doğruluk, %98 recall ve %97 F1-skoru elde edilmiştir. Çalışmada elde edilen yüksek performansın, özellik seçme yöntemleri ile farklı ensemble öğrenme tekniklerinin birlikte kullanılmasından kaynaklandığı belirtilmiştir.

Bu projede ise temel model olarak Random Forest algoritması tercih edilmiş ve model %96,29 doğruluk, %93,33 sensitivity (recall), %97,34 specificity ve %92,95 F1-skoru elde etmiştir. Literatürdeki çalışmaya kıyasla daha düşük doğruluk değeri elde edilmiş olsa da, Random Forest modeli aynı veri seti üzerinde yüksek performans göstermiştir. Ayrıca literatürdeki çalışmada çok sayıda özellik seçme ve ensemble öğrenme tekniği birlikte kullanılırken, bu projede tek bir Random Forest modeli ile literatürdeki sonuçlara yakın performans elde edilmiştir.

Tablo 3 incelendiğinde her iki çalışmanın da aynı Thyroid0387 veri seti üzerinde yüksek performans elde ettiği görülmektedir. Akhtar vd. (2022) çalışmasında daha gelişmiş özellik seçme ve ensemble öğrenme yöntemleri kullanılarak daha yüksek doğruluk değerine ulaşılmıştır. Buna karşın bu çalışmada kullanılan Random Forest modeli, daha basit bir yapı ile %96,29 doğruluk oranı elde ederek literatürdeki sonuçlara yakın bir performans göstermiştir. Bu durum Random Forest algoritmasının tiroid hastalığı sınıflandırmasında başarılı bir yöntem olduğunu göstermektedir.

Çalışma	Veri Seti	Yöntem	Accuracy (%)	Recall (%)	F1-Score (%)
Akhtar vd. (2022)	Thyroid0387	Ensemble Learning + Feature Selection	99.27	98.00	97.00
Bu Çalışma	Thyroid0387	Random Forest	96.29	93.33	92.95

Tablo 3. Literatür Çalışması ile Karşılaştırma

8. Sonuç ve Öneriler

Bu çalışmada UCI Machine Learning Repository’den elde edilen Thyroid0387 veri seti kullanılarak tiroid hastalığının sınıflandırılması amacıyla Random Forest algoritması uygulanmıştır. Veri ön işleme aşamasında eksik ve gereksiz veriler düzenlenmiş, hedef değişken hastalık var ve hastalık yok olmak üzere ikili sınıflandırma problemine dönüştürülmüştür. Daha sonra veri eğitim ve test kümelerine ayrılarak model eğitilmiş ve performansı çeşitli değerlendirme ölçütleri ile analiz edilmiştir.

Gerçekleştirilen deneyler sonucunda Random Forest modeli %96,29 doğruluk (Accuracy), %93,33 duyarlılık (Sensitivity/Recall), %97,34 özgüllük (Specificity) ve %92,95 F1-Skoru elde etmiştir. Elde edilen sonuçlar modelin hem hasta hem de sağlıklı bireyleri yüksek başarıyla sınıflandırabildiğini göstermektedir. Özellikle duyarlılık değerinin yüksek olması,

hastalığa sahip bireylerin doğru şekilde tespit edilmesi açısından önemli bir sonuç olarak değerlendirilmektedir.

Çalışma kapsamında Random Forest algoritmasının performansı Decision Tree algoritması ile karşılaştırılmıştır. Karşılaştırma sonucunda her iki model de yüksek performans göstermiş olup, Decision Tree modeli doğruluk açısından daha yüksek bir değer elde etmiştir. Buna karşın Random Forest modeli, topluluk öğrenme yaklaşımı sayesinde daha kararlı ve genellenebilir sonuçlar sunması nedeniyle çalışmanın temel modeli olarak değerlendirilmiştir. Ayrıca literatürde aynı Thyroid0387 veri seti üzerinde gerçekleştirilen Akhtar vd. (2022) çalışması ile karşılaştırma yapılmıştır. İlgili çalışmada daha gelişmiş özellik seçme ve ensemble öğrenme yöntemleri kullanılarak daha yüksek doğruluk değerleri elde edilmiş olsa da, bu çalışmada kullanılan Random Forest modeli daha basit bir yapıyla literatürdeki sonuçlara yakın performans göstermiştir.

Sonuç olarak Random Forest algoritmasının tiroid hastalığının sınıflandırılmasında etkili ve güvenilir bir yöntem olduğu görülmüştür. Gelecekte yapılacak çalışmalarda veri setindeki sınıf dengesizliğini azaltmaya yönelik yöntemler uygulanabilir. Ayrıca XGBoost, LightGBM ve derin öğrenme tabanlı yaklaşımlar kullanılarak performans değerleri karşılaştırılabilir. Bunun yanında farklı özellik seçme yöntemleri ve daha kapsamlı hiperparametre optimizasyon teknikleri değerlendirilerek model başarısının artırılması hedeflenebilir.

Kaynakça:

- 1) <https://archive.ics.uci.edu/dataset/102/thyroid+disease>
- 2) Akhtar, T., Gilani, S. O., Arif, S., Jamil, M., Butt, S. I., Mushtaq, Z., & Ayaz, Y. (2022). *Ensemble-based Effective Diagnosis of Thyroid Disorder with Various Feature Selection Techniques*. 2022 2nd International Conference of Smart Systems and Emerging Technologies (SMARTTECH), 14–19. IEEE.
- 3) Breiman, L. (2001). Random Forests. Machine Learning : <https://doi.org/10.1023/A:1010933404324>